Evaluasi Empiris Transfer Learning ResNet-18 untuk Klasifikasi Ras Hewan pada Data Terbatas

Andrew Wijaya
Program Studi Computer Science, BINUS University, Jakarta, Indonesia
NIM: 2802508363

Abstract

Penelitian ini membandingkan empat kondisi pelatihan ResNet-18 untuk klasifikasi sepuluh ras hewan pada subset Oxford-IIIT Pet dengan 1.981 citra. Kondisi yang diuji meliputi pelatihan dari nol (B1), *feature extraction* menggunakan backbone ImageNet (B2), *progressive fine-tuning* pada `layer4` dan `fc` dengan augmentasi (B3), serta kontrol tanpa augmentasi (B4). Eksperimen menggunakan pembagian terstratifikasi, satu *random seed*, dan *early stopping*. B3 mencapai akurasi validasi tertinggi (96,30%), sehingga layak menjadi kandidat untuk kajian lanjutan. Akan tetapi, B4 tetap merupakan model yang terpilih dalam eksperimen berdasarkan *validation loss* terendah (0,1841). Nilai *test macro F1* hanya digunakan sebagai evaluasi akhir, bukan sebagai dasar pemilihan ulang. Augmentasi meningkatkan akurasi validasi sebesar 1,35 poin persentase dibandingkan B4 dan mempersempit *generalization gap* sebesar 2,00 poin persentase. Analisis kesalahan memeriksa delapan sampel dari 20 prediksi yang salah pada *test set* B4. Temuan ini menunjukkan manfaat bobot pralatih, dengan keterbatasan hanya satu *seed* dan tanpa validasi eksternal.

Kata kunci: transfer learning, ResNet-18, fine-tuning, data augmentation, Oxford-IIIT Pet, klasifikasi citra.

1. Pendahuluan

Klasifikasi citra dengan data berlabel terbatas menimbulkan kendala ketika jaringan konvolusional harus mempelajari fitur visual sejak awal. *Residual connection* membantu aliran gradien pada jaringan dalam, tetapi tidak menggantikan kebutuhan akan data yang memadai [2]. *Transfer learning* memanfaatkan representasi dari pelatihan skala besar sehingga hanya sebagian parameter perlu diperbarui.

Penelitian ini menguji empat konfigurasi wajib B1–B4 sesuai protokol tugas [1]. Fokus analisis meliputi bobot pralatih, kompromi biaya pembaruan parameter terhadap akurasi, dan kontribusi augmentasi terhadap generalisasi. Seluruh nilai numerik berasal dari log eksperimen yang tersimpan, tanpa mengestimasi hasil yang tidak diukur [3].

2. Metodologi

2.1 Dataset dan protokol

Dataset memakai subset sepuluh kelas Oxford-IIIT Pet yang terdiri atas lima ras kucing dan lima ras anjing. Sebanyak 1.981 citra dibagi secara *stratified* menjadi 1.386 latih (70%), 297 validasi (15%), dan 298 uji (15%). Seluruh eksperimen memakai ResNet-18, resolusi 224×224, normalisasi ImageNet, *batch size* 32, AdamW, dan `CrossEntropyLoss`. Nilai *seed* 42, batas 30 epoch, dan *early stopping* dengan *patience* 5 berdasarkan *validation loss* diterapkan konsisten. Log lingkungan menunjukkan PyTorch `2.11.0+cpu` [3].

2.2 Konfigurasi B1–B4

B1 melatih seluruh ResNet-18 dari bobot acak, dengan laju pembelajaran 10^{-3}. **B2** membekukan seluruh backbone pralatih dan melatih hanya *fully connected head* (10^{-3}). **B3** membuka `layer4` dengan laju 10^{-4} serta `fc` dengan 10^{-3}, menggunakan augmentasi. **B4** menerapkan konfigurasi B3 tanpa augmentasi. Paket augmentasi mencakup *crop*, *horizontal flip*, rotasi, dan *color jitter* yang diterapkan hanya pada data latih [1, 2].

2.3 Metrik dan pemilihan model

Metrik utama ialah akurasi validasi dan *test macro F1*. *Generalization gap* merupakan selisih akurasi *train-eval* terhadap akurasi validasi dalam poin persentase (pp). *Best epoch* dan model terpilih ditentukan menggunakan *validation loss* minimum. Dengan kriteria ini, notebook memilih B4 (0,1841), bukan B3 (0,1868). *Test set*, termasuk nilai *macro F1*, digunakan hanya untuk evaluasi akhir setelah pemilihan; metrik uji tidak dipakai untuk memilih ulang model. B5 (opsional, arsitektur efisien) tidak dijalankan.

Table 1. Ringkasan metrik aktual eksperimen B1–B4; *gap* dalam pp.

Eks.	Strategi	Parameter aktif	Learning rate	Epoch baik/total	Waktu (mnt)	Val. acc.	Macro F1 test	Gap
B1	Scratch, augmentasi	11.181.642	10^{-3}	4/9	63,25	40,40%	35,50%	4,40
B2	Feature extraction, augmentasi	5.130	10^{-3}	13/18	50,05	92,93%	91,32%	2,96
B3	Fine-tuning, augmentasi	8.398.858	$10^{-4}/10^{-3}$	7/12	44,33	**96,30%**	**93,63%**	3,05
B4	Fine-tuning, tanpa augmentasi	8.398.858	$10^{-4}/10^{-3}$	4/9	32,76	94,95%	93,31%	5,05

3. Hasil dan Pembahasan

3.1 Perbandingan B1–B3

B1 menghasilkan akurasi validasi 40,40% dan *macro F1* 35,50% meskipun 11.181.642 parameter dapat diperbarui. *Validation loss* terbaik (1,6999) dicapai pada epoch 4, kemudian pelatihan berhenti setelah sembilan epoch. Temuan ini sesuai dengan kesulitan mempelajari representasi diskriminatif dari dataset kecil, bukan bukti kegagalan *residual connection*.

B2 mencapai akurasi validasi 92,93% dan *macro F1* 91,32% dengan hanya 5.130 parameter aktif. B3 menaikkan metrik tersebut menjadi 96,30% dan 93,63%. Dengan demikian, B3 melampaui B2 sebesar 3,37 pp pada akurasi validasi dan 2,31 pp pada *macro F1*, dengan konsekuensi bertambahnya jumlah bobot yang dilatih menjadi 8.398.858.

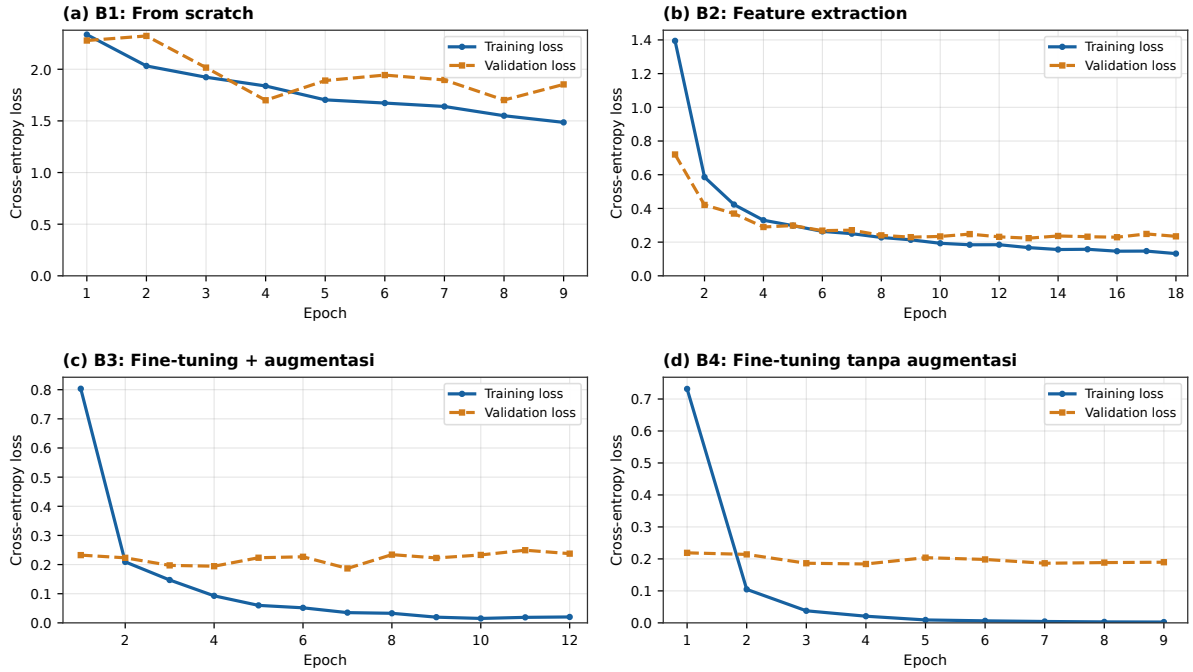


Figure 1. Kurva *training loss* (biru) dan *validation loss* (jingga) untuk B1, B2, B3, serta B4, berdasarkan `history.csv`.

3.2 Dinamika optimisasi dan biaya komputasi

Gambar 1 menunjukkan *training loss* yang menurun, tetapi perbaikan *validation loss* tidak selalu mengikuti. Pada B3, *checkpoint* terbaik berada di epoch 7 dengan *validation loss* 0,1868. B2 memerlukan 18 epoch dan 50,05 menit, sedangkan B3 12 epoch dan 44,33 menit. Total waktu B3 lebih singkat *bukan* karena lebih murah per epoch. Rerata durasi setiap epoch meningkat dari sekitar 167 detik (B2) menjadi 222 detik (B3). Pengukuran dilakukan pada CPU, bukan GPU T4.

3.3 Dampak augmentasi: B3 dibanding B4

Dengan strategi *fine-tuning* yang sama, B3 menghasilkan akurasi validasi 96,30% dibandingkan 94,95% untuk B4 (+1, 35 pp), dan *macro F1* 93,63% dibandingkan 93,31% (+0, 32 pp). *Generalization gap* B3 sebesar 3,05 pp, lebih kecil daripada B4 sebesar 5,05 pp (−2, 00 pp). Akurasi *train-eval* B3 adalah 99,35%, sedangkan B4 mencapai 100,00%. Hal ini secara deskriptif konsisten dengan efek regularisasi paket augmentasi.

Walaupun akurasi validasi B3 lebih tinggi, *validation loss* minimum B4 (0,1841) sedikit lebih rendah daripada B3 (0,1868). Karena kriteria pemilihan dalam notebook adalah *validation loss* minimum, B4 tetap model terpilih untuk evaluasi dan analisis kesalahan. Perbandingan *test macro F1* tidak digunakan untuk mengubah keputusan ini. Satu *seed* tidak mendukung klaim signifikansi statistik, dan desain B4 belum mengisolasi kontribusi tiap jenis augmentasi secara terpisah.

4. Evaluasi Kelas dan Analisis Kesalahan

4.1 Confusion matrix model terpilih

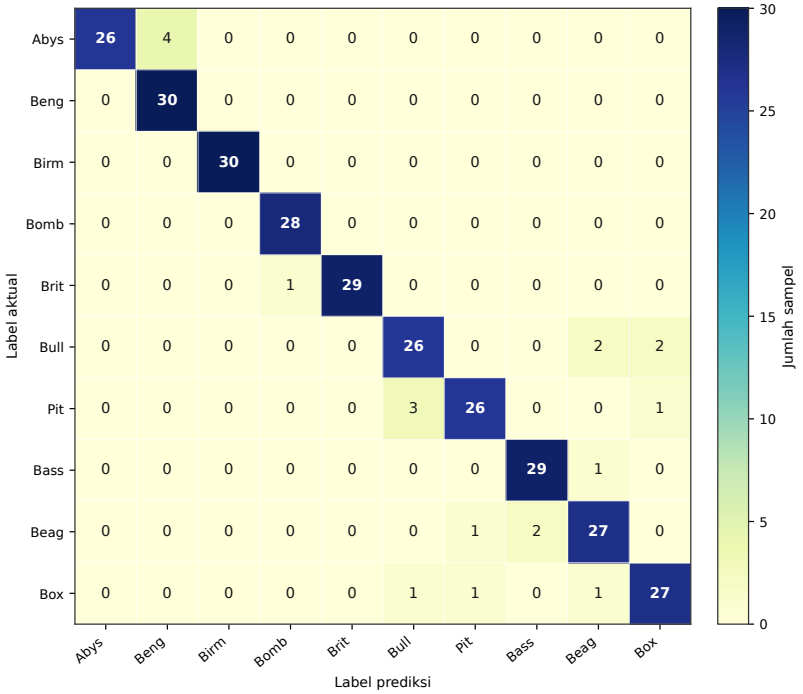


Figure 2. *Confusion matrix* B4 pada 298 citra uji. Kode label: Abys (Abyssinian), Beng (Bengal), Birm (Birman), Bomb (Bombay), Brit (British Shorthair), Bull (American Bulldog), Pit (Pit Bull Terrier), Bass (Basset Hound), Beag (Beagle), dan Box (Boxer).

Model B4 yang terpilih berdasarkan *validation loss* memprediksi 278 dari 298 citra uji secara benar (akurasi 93,29%) dengan *macro F1* 93,31%. Pertukaran terbanyak termasuk Abyssinian→Bengal (4), Pit Bull Terrier→American Bulldog (3), American Bulldog→Boxer (2), serta Beagle→Basset Hound (2). Pada matriks ini tidak ditemukan pertukaran antar-kelompok kucing dan anjing. Kesalahan utamanya muncul saat membedakan karakteristik ras yang serupa.

4.2 Delapan contoh misklasifikasi

Delapan gambar berikut berasal dari sampel *test set* yang salah diprediksi oleh B4. *Ground truth*, prediksi, dan *confidence* diambil dari `failure_analysis.csv`; dugaan penyebab merupakan hasil observasi visual, bukan pembuktian kausal.



Figure 3. Delapan contoh kesalahan B4 dalam warna asli. Nomor gambar sesuai Tabel 2; nilai *confidence* berasal dari keluaran model.

Table 2. Label aktual, prediksi, dan hipotesis pada delapan sampel kesalahan B4.

No.	Aktual > Prediksi (confidence)	Observasi dan hipotesis
1	American Bulldog > Boxer (72,8%)	Subjek jauh dan wajah berbayang; ukuran kecil mungkin menyamarkan ciri pembeda terhadap Boxer.
2	Basset Hound > Beagle (76,0%)	Tubuh tertutup pohon; oklusi mungkin menghilangkan petunjuk proporsi tubuh pembeda terhadap Beagle.
3	Pit Bull Terrier > Boxer (80,7%)	Close-up kepala dan moncong lebar mungkin menyamarkan ciri pembeda Pit Bull Terrier terhadap Boxer.
4	British Shorthair > Bombay (74,8%)	Bayangan dan ketajaman rendah mungkin mengaburkan tekstur bulu serta ciri wajah pembeda terhadap Bombay.
5	Pit Bull Terrier > American Bulldog (82,9%)	Tubuh hanya terlihat sebagian; kemiripan warna bulu dan kepala mungkin menyebabkan kekeliruan antar-ras.
6	Abyssinian > Bengal (68,9%)	Ketajaman rendah dan garis wajah mungkin membuat ciri pembeda Abyssinian terhadap Bengal kurang jelas.
7	Boxer > American Bulldog (94,7%)	Kemiripan moncong pendek dan kepala lebar mungkin menyebabkan kekeliruan terhadap American Bulldog.
8	Abyssinian > Bengal (93,9%)	Pola wajah mungkin menyerupai Bengal; watermark dan oklusi juga mungkin mengganggu petunjuk visual.

Hipotesis ditulis dari gambar sumber, bukan tensor CenterCrop 224 x 224 atau analisis fitur internal model. Kata "mungkin" menunjukkan dugaan yang masih perlu diuji.

5. Rekomendasi dan Batasan

5.1 Rekomendasi implementasi

B3 layak menjadi kandidat ketika validation accuracy diprioritaskan (96,30%). Namun, model terpilih dalam eksperimen ini tetap B4 berdasarkan validation loss terendah (0,1841), sesuai kriteria yang ditetapkan sebelum evaluasi test. Test Macro F1 B3 yang lebih tinggi tidak digunakan untuk memilih ulang model. B2 merupakan baseline adaptasi ringan, dengan 5.130 parameter aktif dan test Macro F1 91,32%. Sebelum penerapan, lakukan pengulangan beberapa seed, validasi eksternal, pengukuran latensi inferensi, dan audit kalibrasi confidence.

5.2 Batasan penelitian

Eksperimen mencakup satu seed (42), satu split, serta sepuluh ras. Pengujian cross-dataset, kalibrasi confidence, dan audit duplikasi semantik belum dilakukan. Durasi diukur pada CPU dan tidak langsung berlaku untuk GPU. B4 menguji paket augmentasi secara agregat; B5 tidak dijalankan. Delapan sampel adalah kesalahan pertama dalam urutan test, bukan sampel acak dari seluruh 20 kesalahan. Hipotesis visual bukan pembuktian kausal.

6. Kesimpulan

Pada subset ini, transfer learning melampaui scratch. B3 mencapai validation accuracy 96,30% dan test Macro F1 93,63%; B2 menawarkan kompromi dengan hanya 5.130 parameter aktif. Augmentasi memperkecil generalization gap sebesar 2,00 poin persentase dan menambah Macro F1 sekitar 0,32 poin persentase pada satu seed. B4, model terpilih berdasarkan validation loss, memiliki 20 kesalahan dari 298 sampel test. Hasil tidak membuktikan signifikansi statistik atau kesiapan produksi.

Pernyataan Penggunaan AI

ChatGPT dan Codex membantu pengembangan/review kode, penyusunan draf narasi dan jawaban konseptual, pemformatan PDF, visualisasi, serta usulan hipotesis. Metrik diperiksa terhadap experiment_summary.csv, history.csv, augmentation_delta.csv, test_predictions.csv, dan failure_analysis.csv; Macro F1 juga dihitung ulang dari prediksi test. Tidak ada training baru untuk revisi ini. Penulis perlu memverifikasi dan memahami jawaban serta menulis ulang interpretasi sesuai pemahaman mandiri; laporan ini tidak mengklaim seluruh narasi disusun tanpa bantuan AI.

References

[1] Tugas Take-Home Sesi 05: Transfer Learning untuk Klasifikasi Citra dengan Data Terbatas, dokumen penugasan, Oktober 2026.

[2] K. He, X. Zhang, S. Ren, J. Sun. Deep Residual Learning for Image Recognition. CVPR, 2016. https://arxiv.org/abs/1512.03385

[3] Tugas05 experiment outputs: arsip log dan prediksi eksperimen B1-B4, 2026. Referensi ilmiah tambahan untuk Bagian A tercantum pada halaman 5.

Lampiran A. Analisis Konseptual

Andrew Wijaya | NIM: 2802508363. Rujukan slide mengikuti PDF tugas dan bahan tayang Advanced CNNs and Transfer Learning yang telah diperiksa. Materi augmentasi ada pada Slide 20-22; Slide 23 yang disebut pertanyaan tugas merupakan pembuka Modern Architectures.

A1. Efek regularisasi Batch Normalization (Slide 6-8)

Batch Normalization menormalkan aktivasi menggunakan mean dan variance mini-batch saat training. Karena anggota setiap batch berubah, estimasi statistik ikut berfluktuasi. Akibatnya, aktivasi menerima variasi yang dapat bertindak sebagai regularisasi ringan dan mengurangi ketergantungan model pada contoh tertentu. Saat evaluasi, running statistics digunakan agar prediksi konsisten. Namun, efek ini tidak berarti Dropout selalu dapat dihilangkan. Dataset sangat kecil dengan model berkapasitas besar masih berisiko overfitting. Batch terlalu kecil juga menghasilkan estimasi statistik yang kurang stabil, sedangkan pergeseran distribusi dapat membuat running statistics tidak representatif. BatchNorm dan Dropout bekerja melalui mekanisme berbeda: normalisasi aktivasi versus penghilangan unit secara acak. Karena itu, keputusan memakai Dropout harus didasarkan pada validation performance, bukan aturan universal. [4]

A2. Degradasi dan residual connection (Slide 10-12)

Degradation problem terjadi ketika jaringan lebih dalam menghasilkan training error lebih tinggi daripada jaringan dangkal. Masalah ini berbeda dari overfitting karena kualitas pada data training sendiri memburuk. Secara teoritis, lapisan tambahan dapat mempertahankan keluaran melalui identity mapping, tetapi proses optimasi plain CNN tidak otomatis menemukan pemetaan tersebut. Residual connection mengubah target pembelajaran menjadi residual: $y = x + F(x)$. Jika perubahan tidak diperlukan, blok cukup membuat $F(x)$ mendekati nol. Pada backpropagation, gradien terhadap input menjadi $dL/dx = dL/dy \times (I + dF/dx)$. Komponen identitas menyediakan jalur langsung bagi gradien, sehingga mengurangi ketergantungan pada perkalian turunan banyak lapisan. Ini membantu mitigasi vanishing gradient dan mempermudah optimasi, meskipun tidak menjamin semua persoalan training hilang. [2]

A3. Feature extraction dan fine-tuning (Slide 14-16)

Feature extraction membekukan backbone dan hanya memperbarui classifier head. Jumlah trainable parameters sedikit; pada ResNet-18 dengan sepuluh kelas, head memiliki 5.130 parameter. Pendekatan ini sering sesuai untuk data terbatas dengan karakteristik visual dekat domain pretrained. Backbone tetap melakukan forward, tetapi tidak memerlukan backward untuk bobotnya, sehingga biaya komputasi dan memori training lebih rendah. Fine-tuning membuka sebagian atau seluruh backbone, meningkatkan parameter aktif serta biaya backward. Adaptasi ini dapat membantu ketika fitur pretrained belum cukup sesuai, tetapi membutuhkan bukti validation yang memadai dan pengaturan learning rate hati-hati. Update agresif berisiko merusak representasi awal. Pilihan praktis dimulai dari feature extraction, kemudian mempertimbangkan fine-tuning bila peningkatan validation performance sepadan dengan biaya dan risiko overfitting. [5]

A4. Kaidah data augmentation (Slide 20-22; rujukan tugas: 20, 21, 23)

Augmentasi pada train set menambah variasi tampilan agar model tidak terlalu bergantung pada posisi, pencahayaan, atau contoh tertentu. Transformasi harus mempertahankan informasi yang mendukung label. Validation dan test memakai transformasi deterministik agar perubahan skor mencerminkan perbedaan model, bukan variasi gambar evaluasi yang berubah setiap pengukuran. Validation digunakan untuk pemilihan checkpoint, sedangkan test mengukur performa setelah keputusan eksperimen ditetapkan. Contoh transformasi yang tidak layak untuk klasifikasi ras adalah crop ekstrem yang hanya menyisakan latar belakang. Walaupun label tersimpan tetap sama, ciri hewan yang membedakan ras sudah hilang sehingga asumsi invariansi semantik tidak terpenuhi. Karena itu, kekuatan augmentasi harus dibatasi dan contoh hasilnya perlu diperiksa secara visual. Pada eksperimen ini, B4 mengevaluasi paket augmentasi secara keseluruhan.

A5. Mitigasi catastrophic forgetting (Slide 28-29)

Catastrophic forgetting terjadi ketika adaptasi pada data baru mengubah representasi yang sebelumnya berguna sehingga kemampuan awal berkurang. Pada dataset kecil, gradien dari head baru dan learning rate besar dapat mendorong backbone menuju fitur terlalu khusus terhadap training set. Strategi pertama adalah differential learning rate: backbone memakai learning rate lebih kecil daripada head agar representasi awal berubah perlahan sementara classifier menyesuaikan label baru. Strategi kedua adalah gradual unfreezing: latih head terlebih dahulu, kemudian buka blok backbone bertahap. Cara ini membatasi perubahan fitur ketika head masih belum stabil dan mengontrol kapasitas adaptasi. Kedua strategi perlu dievaluasi melalui validation loss. B3 mengikuti ketentuan eksplisit tugas dengan membuka layer4 dan fc sejak awal, sehingga tidak diklaim sebagai gradual unfreezing bertahap. [6]

Referensi ilmiah tambahan

[4] S. Ioffe, C. Szegedy. Batch Normalization. ICML, PMLR 37:448-456, 2015. https://proceedings.mlr.press/v37/ioffe15.html
[5] J. Yosinski et al. How transferable are features in deep neural networks? NeurIPS, 2014. https://arxiv.org/abs/1411.1792
[6] J. Howard, S. Ruder. Universal Language Model Fine-tuning for Text Classification. ACL, 2018. https://arxiv.org/abs/1801.06146. Sumber strategi fine-tuning pada NLP, bukan bukti eksperimen CNN.